#### Aula 08 – Radix Sort

#### Prof. Eduardo Zambon

Departamento de Informática (DI) Centro Tecnológico (CT) Universidade Federal do Espírito Santo (UFES)

Estrutura de Dados II (ED2)

Aula 08 – Radix Sort 1/65

#### Introdução

- Até agora: abstrair os itens a serem ordenados com a definição de uma chave de ordenação e fazer comparação de chaves.
- Outro método: algoritmos de ordenação por radicais (radix sorting) trabalham diretamente com os "dígitos" das chaves, comparando-as em partes.
- Aula de hoje: apresentação das diferentes implementações de radix e dos algoritmos de ordenação radix sort.
- Objetivos: compreender as aplicações e o funcionamento do método de ordenação radix sort.

#### Referências

#### Chapter 10 - Radix Sorting

R. Sedgewick

Aula 08 – Radix Sort 2/65

#### Parte I

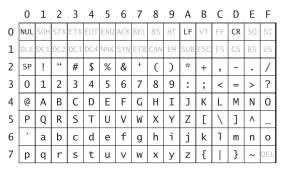
## Strings e Alfabetos

Aula 08 – Radix Sort 3/65

#### Tipo de dado char

#### Tipo de dado char em C:

- Tipicamente é um inteiro de 8 bits.
- Suporta a codificação ASCII de 7 bits.
- Pode representar no máximo 256 caracteres.



Hexadecimal to ASCII conversion table

Em Java: suporta Unicode 16 de bits.

Aula 08 – Radix Sort 4/65

#### Strings em C

#### Tipo de dado string em C:

- Linguagem não possui um tipo string explícito.
- Representado por um char\*.
- Como arrays em C não carregam o seu próprio tamanho, strings são terminadas pelo caractere '\0'.
- Maior parte das operações implementadas em string.h.

Strings em C são mutáveis ⇒ Cuidado ao usar como chaves!

Manipulação de *strings* em C é muito propensa a erros. Exemplo:

```
int main() {
    char *s = "abc";
    s[0] = 'd'; // 'a' to 'd'
    // Segmentation fault... -_-
}
```

Aula 08 – Radix Sort 5/65

## Novo tipo de dado String

Novo tipo String para evitar o inferno astral de ter de lidar com array de char terminado por ' $\$ \0'.

```
typedef struct {
   char *c;
   int len;
} String;
```

#### Vantagens:

- Pode ajudar na imutabilidade tornando a estrutura opaca.
- Obter o tamanho de uma string agora é constante.
- Elimina erros como do slide anterior já que todas as strings são alocadas no heap.

Aula 08 – Radix Sort 6/65

## Novo tipo de dado String: operações

#### Comparar duas *strings* a partir do caractere na posição *d*.

```
int compare_from(String *s, String *t, int d) {
   int min = s->len < t->len ? s->len : t->len;
   for (int i = d; i < min; i++) {
      if (s->c[i] < t->c[i]) { return -1; }
      if (s->c[i] > t->c[i]) { return 1; }
   }
   return s->len - t->len;
}
```

#### Retorna:

- -1: se s < t.
- 1: se s > t.
- 0: se s = t.

#### Atenção:

- Se s é prefixo de t, retorna < 0.
- Exemplo: she < shells.

Aula 08 – Radix Sort 7/65

## Novo tipo de dado String: operações

## Demais operações são triviais de implementar a partir de compare\_from.

```
int compare(String *s, String *t) {
   return compare_from(s, t, 0);
}
```

#### Interface usual de Item também fica simples.

Aula 08 – Radix Sort 8/65

## Comparando duas strings

Q: Quantas comparações de caracteres são necessárias para comparar duas strings de comprimento *W*?

р	r	e	f	е	t	С	h
0	1	2	3	4	5	6	7
р	r	e	f	i	Х	е	S

Tempo de execução: Proporcional ao comprimento do maior prefixo em comum.

- Proporcional a W no pior caso.
- Mas geralmente é sublinear em relação a W.

Aula 08 – Radix Sort 9/65

#### **Alfabetos**

*String*: Sequência de símbolos (caracteres, dígitos) sobre um alfabeto fixo.

Radix: Número R de símbolos de um alfabeto (tamanho).

name	R()	lgR()	characters
BINARY	2	1	01
OCTAL	8	3	01234567
DECIMAL	10	4	0123456789
HEXADECIMAL	16	4	0123456789ABCDEF
DNA	4	2	ACTG
LOWERCASE	26	5	abcdefghijklmnopqrstuvwxyz
UPPERCASE	26	5	ABCDEFGHIJKLMNOPQRSTUVWXYZ
PROTEIN	20	5	ACDEFGHIKLMNPQRSTVWY
BASE64	64	6	ABCDEFGHIJKLMNOPQRSTUVWXYZabcdef ghijklmnopqrstuvwxyz0123456789+/
ASCII	128	7	ASCII characters
EXTENDED_ASCII	256	8	extended ASCII characters
UNICODE16	65536	16	Unicode characters

Aula 08 – Radix Sort 10/65

#### Parte II

# Contagem Indexada por Chaves Key-Indexed Counting

Aula 08 – Radix Sort 11/65

## Sumário: desempenho dos algoritmos de ordenação

Quantidade de operações feita por cada algoritmo.

algorithm	guarantee	random	extra space	stable?
insertion sort	½ N²	1/4 N <sup>2</sup>	1	~
mergesort	N lg N	$N \lg N$	N	~
quicksort	1.39 N lg N *	1.39 N lg N	c lg N	
heapsort	3 N lg N	3 N lg N	1	
	* probabilistic			

Limite inferior: pelo menos  $\sim N \lg N$  comparações.

- Q: É possível fazer melhor? (Apesar do limite inferior.)
- A: Sim, evitando comparação de chaves.
- Comparação de chaves: decisões binárias.
- Comparação por radix R: decisões têm R resultados.

Aula 08 – Radix Sort

## Key-indexed counting: suposições sobre as chaves

Suposição: chaves são inteiros entre  $0 \in R - 1$ .

Implicação: podemos usar as chaves como índices de *array*.

#### Aplicações:

- Ordenar uma string pela primeira letra.
- Ordenar empregados por seção.
- Ordenar números de telefone por código de área.
- Sub-rotina em um algoritmo de ordenação (em breve).

input		sorted result	
	ection	(by section)	
Anderson	2	Harris	1
Brown	3	Martin	1
Davis	3	Moore	1
Garcia	4	Anderson	2
Harris	1	Martinez	2
Jackson	3	Miller	2
Johnson	4	Robinson	2
Jones	3	White	2
Martin	1	Brown	3
Martinez	2	Davis	3
Miller	2	Jackson	3
Moore	1	Jones	3
Robinson	2	Taylor	3
Smith	4	Williams	3
Taylor	3	Garcia	4
Thomas	4	Johnson	4
Thompson	4	Smith	4
White	2	Thomas	4
Williams	3	Thompson	4
Wilson	4	Wilson	4
	<b>†</b>		
	keys are		
sma	ıll integers		

Aula 08 – Radix Sort

Objetivo: ordenar um array a[] de N inteiros entre 0 e R-1.

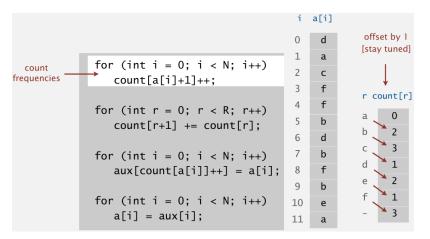
- Vetor auxiliar 1: count[] de tamanho R + 1.
- Vetor auxiliar 2: aux [] de tamanho N.
- No exemplo abaixo: R = 6.

```
a[i]
for (int i = 0; i < N; i++)
   count[a[i]+1]++;
for (int r = 0; r < R; r++)
   count[r+1] += count[r]:
for (int i = 0; i < N; i++)
                                             f for 5
   aux[count[a[i]]++] = a[i]
for (int i = 0; i < N; i++)
                               9
                                   b
   a[i] = aux[i];
                              10
```

Aula 08 – Radix Sort 14/65

Objetivo: ordenar um array a [] de N inteiros entre 0 e R-1.

■ P.1: Contar a frequência de cada valor usando count [].



Aula 08 – Radix Sort 15/65

Objetivo: ordenar um *array* a [] de N inteiros entre 0 e R-1.

P.2: Computar a frequência acumulada.

```
a[i]
              for (int i = 0; i < N; i++)
                 count[a[i]+1]++;
                                                            a
                                                                   r count[r]
                                                           c
              for (int r = 0; r < R; r++)
compute
                 count[r+1] += count[r];
cumulates
              for (int i = 0; i < N; i++)
                 aux[count[a[i]]++] = a[i];
                                                            f
              for (int i = 0; i < N; i++)
                                                            b
                                                       9
                                                                        12
                 a[i] = aux[i];
                                                      10
                                                            e
                                                      11
                                                            а
                                                       6 keys < d, 8 keys < e
                                                       so d's go in a [6] and a [7]
```

Aula 08 – Radix Sort 16/65

Objetivo: ordenar um array a [] de N inteiros entre 0 e R-1.

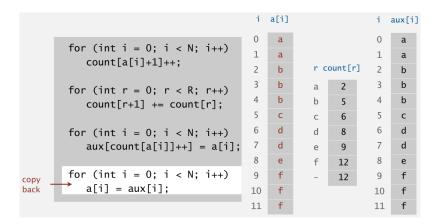
■ P.3: Mover os itens para um vetor auxiliar.

```
a[i]
                                                                       aux[i]
                                                                         a
        for (int i = 0; i < N; i++)
                                                а
                                                                         а
            count[a[i]+1]++:
                                                       r count[r]
                                                C
                                                                         b
                                                                         b
        for (int r = 0; r < R; r++)
                                                                         b
            count[r+1] += count[r]:
                                                 b
                                                                         C
                                                d
                                                                         d
        for (int i = 0; i < N; i++)
move
            aux[count[a[i]]++] = a[i];
                                                 b
                                                                         d
items
                                                            12
        for (int i = 0; i < N; i++)
                                                 b
                                                            12
            a[i] = aux[i];
                                                                    10
                                           10
                                                 е
                                           11
                                                                    11
                                                 a
```

Aula 08 – Radix Sort 17/65

Objetivo: ordenar um array a [] de N inteiros entre 0 e R-1.

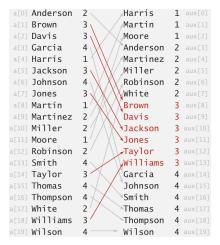
■ P.4: Copiar de volta para o vetor original (se necessário).



Aula 08 – Radix Sort 18/65

## Key-indexed counting: análise

- Tempo de execução é  $\sim 3N + R$ .
- **E**spaço extra é  $\sim N + R$ .
- Método é estável.



Aula 08 – Radix Sort 19/65

#### Key-indexed counting: implementação em C

#### Versão final generalizada para uso em outros sorts:

■ Faz a contagem sobre o d-ésimo caractere.

```
void count_sort(String* *a, String* *aux, int *count,
                int lo, int hi, int d, int R) {
    clear count array(count, R);
    for (int i = lo; i <= hi; i++) { // Count frequencies.</pre>
        count[char at(a[i], d) + 2]++;
    for (int r = 0; r < R+1; r++) { // Compute cumulates.
        count[r+1] += count[r];
    for (int i = lo; i <= hi; i++) { // Move items.
        int p = count[char at(a[i], d) + 1]++;
        aux[p] = a[i];
    for (int i = lo; i <= hi; i++) { // Copy back.
        a[i] = aux[i - lo];
```

Aula 08 – Radix Sort 20/65

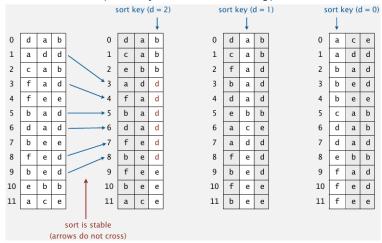
#### Parte III

## LSD Radix Sort

Aula 08 – Radix Sort 21/65

## LSD (Least Significant Digit) radix sort

- Considera os caracteres da direita para a esquerda.
- Faz uma ordenação estável usando o d-ésimo caractere como chave (usa key-indexed counting).



Aula 08 – Radix Sort 22/65

## LSD radix sort: correção

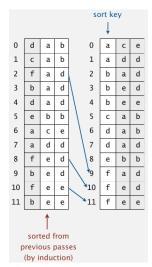
Proposição: LSD ordena *strings* de tamanho fixo de forma ascendente.

Prova (por indução em i):

Depois da passada *i*, as *strings* estão ordenadas pelos <u>últimos</u> *i* caracteres.

- Duas strings com chave de ordenação diferentes: key-indexed sort as coloca na ordem relativa adequada.
- Duas strings com chave de ordenação iguais: estabilidade as mantém ordem relativa adequada.

LSD sort é estável porque key-indexed sort é estável.



Aula 08 – Radix Sort 23/65

## LSD radix sort: implementação em C

```
void sort(String* *a, int N) {
    int W = 3; // Change accordingly to input size.
    int R = 256;
    String* *aux = create_str_array(N);
    int* count = create_count_array(R);
    for (int d = W-1; d >= 0; d--) {
        count_sort(a, aux, count, 0, N-1, d, R);
    free (count):
    free (aux);
```

Aula 08 – Radix Sort 24/65

## Sumário: desempenho dos algoritmos de ordenação

Quantidade de operações feita por cada algoritmo.

algorithm	guarantee	random	extra space	stable?
insertion sort	½ N <sup>2</sup>	1/4 N <sup>2</sup>	1	V
mergesort	N lg N	N lg N	N	V
quicksort	1.39 N lg N*	1.39 N lg N	c lg N	
heapsort	3 N lg N	3 N lg N	1	
LSD sort †	W(3N+R)	W (3N + R)	N + R	•
† fixed-length W keys	* probabilistic			

Q: E se as strings não são todas do mesmo tamanho?

Aula 08 – Radix Sort 25/65

#### Como fazer um censo nos anos de 1900?

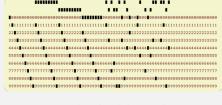
#### Censo de 1880 (nos EUA):

- 1500 pessoas processando manualmente os dados.
- Processamento levou 7 anos.

Herman Hollerith: Desenvolveu uma máquina para automatizar a contagem e ordenação.

- Usou cartões perfurados para registrar os dados.
- Máquina ordena uma coluna por vez (em 12 pilhas).





Hollerith tabulating machine and sorter

punch card (12 holes per column)

Censo de 1890: Completado em 1 ano.

Aula 08 – Radix Sort 26/65

#### Como ficar rico ordenando nos anos de 1900?

#### Cartões perfurados (1900 a 1950):

- Também eram úteis para contabilidade, inventário e outros processos de negócios.
- Principal mídia para entrada, armazenamento e processamento de dados.

A empresa de Hollerith depois se fundiu com mais 3 outras para formar a Computing Tabulating Recording Corporation (CTRC). Empresa foi renomeada em 1924.



Aula 08 – Radix Sort 27/65

## LSD radix sort: um momento na história (1960s)







punched cards



card reader



mainframe



line printer

#### To sort a card deck

- start on right column
- put cards into hopper
- machine distributes into bins
- pick up cards (stable)
- move left one column
- continue until sorted



card sorter





Lysergic Acid Diethylamide (Lucy in the Sky with Diamonds)

Aula 08 – Radix Sort 28/65

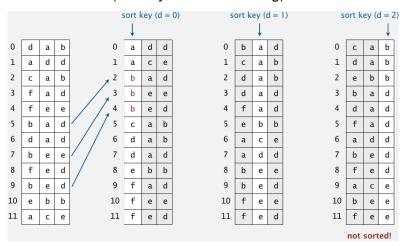
#### Parte IV

## MSD Radix Sort

Aula 08 – Radix Sort 29/65

#### LSD invertido

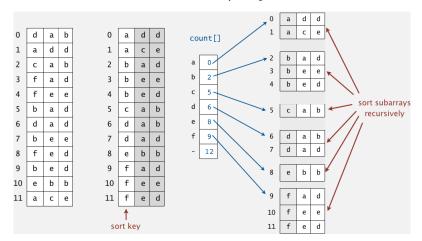
- Considera os caracteres da esquerda para a direita.
- Faz uma ordenação estável usando o *d*-ésimo caractere como chave (usa *key-indexed counting*).



Aula 08 – Radix Sort 30/65

## MSD (Most Significant Digit) radix sort

- Particiona o array em R partes segundo o primeiro caractere, usando key-indexed counting.
- Ordena recursivamente cada partição.



Aula 08 – Radix Sort 31/65

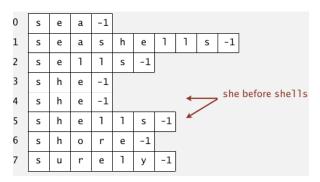
## MSD radix sort: exemplo

input		d						
she	are	arte	are	are	are	are	are	are
sells	by 10	by	by	by	by	by	by	by
seashells		sells	se <b>a</b> shells	sea	sea	sea	seas	sea
by	sells	s <b>e</b> ashells	sea	sea <b>s</b> hells	seashells		seashells	seashells
the	seashells						seashells	seashells
sea	sea	sells	se <b>l</b> ls	sells	sells	sells	sells	sells
shore	shore	s <b>e</b> ashells	se <b>l</b> ls	sells	sells			sells
the	shells	she	she		she			
shells	she	shore	shore	shore	shore	shore	shore	shore
she	sells	shells	shells	shells	shells	shells	shore	shells
sells	<b>s</b> urely	s <b>h</b> e	she	she	she	she	she	she
are	seashells	surely	surely	surely	surely	surely	surely	surely
surely	the hi	the	the	the	the	the	the	the
seashells	<b>t</b> he	the	the	the	the	the	the	the
		,	every character				f string fore any	
			in equal keys			/ char	value	output
	are	are	are	are	are	are	value are	are
	by	by	are by	by	by	are by	value are by	are by
	by sea	by sea	are by sea	by sea	by sea	are by	value are by sea	are by sea
	by sea seashells	by sea seashells	are by sea seashells	by sea seashells	by sea seashells	are by sea seashells	value are by sea s seashells	are by sea seashells
	by sea seashells seashells	by sea seashells seashells	are by sea seashells seashells	by sea seashells seashells	by sea seashells seashell	char are by sea seashells seashells	value are by sea seashells seashells	are by sea seashells seashells
	by sea seashells seashells sells	by sea seashells seashells sells	are by sea seashells seashells sells	by sea seashells seashells sells	by sea seashells seashell sells	are by sea seashells seashells	value are by sea s seashells seals	are by sea seashells seashells sells
	by sea seashells seashells sells sells	seashells seashells sells sells	are by sea seashells seashells sells	by sea seashells seashells sells sells	by sea seashells seashells sells sells	are by sea seashells seashells sells	value are by sea s seashells sealls sells sells	are by sea seashells seashells sells sells
	by sea seashells seashells sells sells she	by sea seashells seashells sells sells she	are by sea seashells seashells sells sells she	by sea seashells seashells sells sells she	by sea seashells seashell sells sells she	are by sea seashells seashells sells she	value are by sea s seashells s seashells sells sells she	are by sea seashells seashells sells sells sells
	by sea seashells seashells sells sells she shore	by yea seashells seashells sells sells she sshore	are by sea seashells seashells sells sells she shore	by sea seashells seashells sells sells she shells	by sea seashells seashells sells sells she she	are by sea seashells seashells sells sells she she	value are by sea seashells seashells sells sells sells she she	are by sea seashells seashells sells sells sells she
	by sea seashells seashells sells sells she shore shells	by yea seashells seashells sells sells she sshore hells	are by sea seashells seashells sells sells she shore shells	by sea seashells seashells sells sells she shells she	by sea seashells seashells sells sells she she she she she she she she seashells	char are by sea seashells seashells sells sells sells she she shells	value are by sea seashells seashells sells sells sells she she	are by sea seashells seashells sells sells sells
	by sea seashells seashells sells sells she shore	by sea seashells sealls sells she sshore hells she	are by sea seashells seashells sells sells she shore shells she	by sea seashells seashells sells sells sells she she she	by sea seashells seashells sells sells she she she shore	char are by sea seashells seashells sells sells she she she shore	value are by sea seashells sealls sells sells she she shore	are by sea seashells seashells sells sells sells she she she she shore
	by sea seashells seashells sells she shore shells she	by yea seashells seashells sells sells she sshore hells	are by sea seashells seashells sells sells she shore shells	by sea seashells seashells sells sells she shells she	by sea seashells seashells sells sells she she she she she she she she seashells	char are by sea seashells seashells sells sells sells she she shells	value are by sea seashells seashells sells sells sells she she	are by sea seashells seashells sealls sells sells sells she she she
	by sea seashells seashells sells she shore shells she surely	by sea seashells seashells sells sells she sshore hells she surely	are by sea seashells seashells sells sells she shore shells she surely	by sea seashells seashells sells sells she shells she shore surely	by sea seashells seashells sells she she shells shore surely	char are by sea seashells sealls sells sells she she she sherls shore surely	value are by sea seashells seals sells sells sells sells she she shells shore surely	are by sea seashells sealls sells sells she she shells shore surely
	by sea seashells seashells sells sells she shore shells she surely the the	by sea seashells seashells seils seils she sshore hells she surely the	are by sea seashells seashells sells sells she shore shells she surely the	by sea seashells seashells sells sells she shells she shore surely the the	by sea seashells seashells sells she she shore surely the the	char are by sea seashells sealls sells sells she she she she shere surely the	walue are by sea seashells seals seals sells sells she she she shells surely the the	are by sea seashells sealls sells sells she she she sherls shore surrely the

Aula 08 – Radix Sort 32/65

## Strings de tamanho variável

Considerar que as *strings* têm um caractere extra no final menor que todos os outros.



Implementação em C é bem simples.

```
#define char_at(S, D) ((D < S->len) ? S->c[D] : -1)
```

Aula 08 – Radix Sort 33/65

## MSD radix sort: implementação em C

Caractere "-1" fica na posição 1 de count.

```
for (int i = lo; i <= hi; i++) // Count frequencies.
    count[char_at(a[i], d) + 2]++;</pre>
```

Código abaixo reutiliza aux mas não count. Necessário porque chamadas recursivas modificariam o vetor count.

```
#define R 256
void rec_MSD(String* *a, String* *aux, int lo, int hi, int d) {
  if (hi <= lo) return;</pre>
  int* count = create count array(R);
  count_sort(a, aux, count, lo, hi, d, R); // Key-indexed count.
  for (int r = 1; r < R+1; r++) // Sort R arrays recursively.
    rec MSD(a, aux, lo + count[r], lo + count[r+1] - 1, d+1);
  free (count):
void sort(String* *a, int N) {
  String* *aux = create_str_array(N);
 rec MSD(a, aux, 0, N-1, 0);
  free (aux):
```

Aula 08 – Radix Sort 34/65

#### MSD radix sort: problemas de desempenho

Observação 1: algoritmo muito lento para sub-arrays pequenos.

- Cada chamada de função precisa do seu próprio array count.
- Tabela ASCII: array tem tamanho 256.
- Unicode: array tem tamanho 65,536!
- Mesmo para ordenar um sub-array de tamanho 2 é necessário alocar o array count todo: não sabemos o conteúdo a ser ordenado.

Observação 2: temos um grande número de *sub-arrays* pequenos por causa da recursão.

Aula 08 – Radix Sort 35/65

#### Cut-off para insertion sort

Solução: *cut-off* para *insertion sort* para *sub-arrays* pequenos.

*Insertion sort*, mas começando no *d*-ésimo caractere.

```
void insert_sort_from(Item *a, int lo, int hi, int d) {
   for (int i = lo; i <= hi; i++) {
      for (int j = i; j > lo && less_from(a[j], a[j-1], d); j--) {
        exch(a[j], a[j-1]);
      }
   }
}
```

Relembrando: função  $less\_from()$  compara as *strings* a partir do d-ésimo caractere.

Modificar a função recursiva como de costume.

```
void rec_MSD(String* *a, String* *aux, int lo, int hi, int d) {
   if (hi <= lo + CUTOFF - l) {
      insert_sort_from(a, lo, hi, d);
      return;
   }</pre>
```

Aula 08 – Radix Sort 36/65

## MSD radix sort: desempenho

- MSD examina o mínimo de caracteres necessários para ordenar as chaves.
- Número de caracteres examinados depende das chaves.
- Pode ser sub-linear (no melhor caso) em relação ao tamanho da entrada!

Random (sublinear)	Non-random with duplicates (nearly linear)	Worst case (linear)
<b>1E</b> I0402	are	1DNB377
<b>1H</b> YL490	by	1DNB377
<b>1R</b> 0Z572	sea	1DNB377
<b>2H</b> XE734	seashells	1DNB377
<b>2I</b> YE230	seashells	1DNB377
2X0R846	sells	1DNB377
3CDB573	sells	1DNB377
3CVP720	she	1DNB377
<b>3I</b> GJ319	she	1DNB377
3KNA382	shells	1DNB377
3TAV879	shore	1DNB377
4CQP781	surely	1DNB377
<b>4Q</b> GI284	the	1DNB377
<b>4Y</b> HV229	the	1DNB377
Character	s examined by MSD	string sort

Aula 08 – Radix Sort 37/65

# Sumário: desempenho dos algoritmos de ordenação

algorithm	guarantee	random	extra space	stable?
insertion sort	½ N <sup>2</sup>	1/4 N <sup>2</sup>	1	V
mergesort	$N \lg N$	$N \lg N$	N	V
quicksort	1.39 N lg N*	1.39 N lg N	c lg N	
heapsort	3 N lg N	3 N lg N	1	
LSD sort †	W (3N + R)	W(3N+R)	N + R	V
MSD sort ‡	W(3N+R)	$N \log_R N$	N + D R <b>1</b>	V
<ul><li>* probabilistic</li><li>† fixed-length W keys</li><li>‡ average-length W keys</li></ul>			call stack depth est prefix match	)

Aula 08 – Radix Sort 38/65

## MSD radix sort: análise empírica

#### Casos de teste:

- dict: dicionário com as palavras embaralhadas contendo 370,099 palavras distintas.
- book: versão em texto simples do livro Guerra e Paz, de Liev Tolstói. Contém 562,639 palavras (com repetições).

Algorithm	dict	book	
System qsort	0.409	0.559	
Standard quick sort	0.430	0.499	
Key-counting sort (Only w	orks with	strings	of len = $1$ )
LSD	0.967	0.601	
MSD1: standard	1.327	0.309	
MSD2: cut-off ins-sort	0.229	0.202	

Note como cut-off para insertion sort faz diferença no MSD!

Aula 08 – Radix Sort 39/65

## MSD radix sort vs. quick sort

#### Desvantagens do MSD radix sort.

- Espaço extra para aux[] e count[].
- Loop interno tem muitas instruções.
- Acessa a memória "aleatoriamente" (ruim para cache).

#### Desvantagens do quick sort.

- Número de comparações de strings não é linear.
- Precisa examinar várias vezes os mesmos caracteres quando há prefixos iguais longos.

#### Objetivo:

- Combinar as vantagens de MSD e quick sort.
- Vantagem do MSD: examina cada caractere uma vez.
- Vantagem do *quicksort*: *loop* interno simples, faz bom uso do cache.

Aula 08 – Radix Sort 40/65

## American flag sort

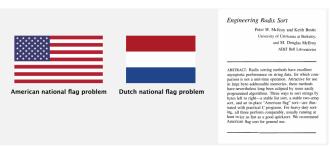
Otimização 0: cut-off para insertion sort.

Otimização 1: Substituir recursão por uma pilha explícita.

- Empilha os *sub-arrays* a serem ordenados na pilha. (Igual *quick sort* não-recursivo.)
- Feito isso, basta um único array count [].

Otimização 3: Faça o particionamento R-way in place.

- Elimina o array aux[].
- Sacrifica estabilidade.



Aula 08 – Radix Sort 41/65

## Parte V

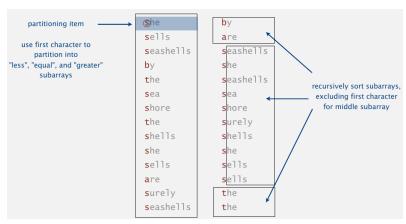
# 3-Way Radix Quick Sort

Aula 08 – Radix Sort 42/65

## 3-way radix quick sort (Bentley & Sedgewick, 1997)

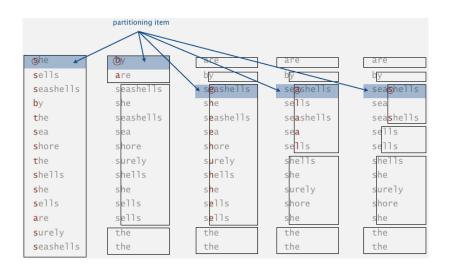
Visão geral: faz particionamento 3-way sobre o d-ésimo char.

- Menos *overhead* que particionamento *R-way* do MSD.
- Não re-examina caracteres iguais ao pivô. (Mas re-examina os caracteres diferentes do pivô.)



Aula 08 – Radix Sort 43/65

## 3-way radix quick sort: trace da recursão



Aula 08 – Radix Sort 44/65

## 3-way radix quick sort: implementação em C

```
void quick sort(String* *a, int lo, int hi, int d) {
    if (hi <= lo) return;</pre>
    int lt = lo, \alphat = hi; //3-wav partitioning
    char v = a[lo] - c[d]; // (using dth character).
    int i = lo + 1;
    while (i <= qt) { // Partition.</pre>
        char t = a[i] - c[d]:
        if (t < v) { exch(a[lt], a[i]); lt++; i++; }</pre>
        else if (t > v) { exch(a[i], a[gt]); gt--; }
        else
                      { i++: }
    quick sort(a, lo, lt-1, d); // Sort 3 sub-arrays
    if (v > 0) { quick_sort(a, lt, qt, d+1); }
    quick_sort(a, qt+1, hi, d); // recursively.
void sort(String* *a, int N) {
    quick sort(a, 0, N-1, 0);
```

Aula 08 – Radix Sort 45/65

## Ordenação de strings: comparação de algoritmos

#### Quick sort padrão:

- Usa ~ 2N In N comparações de strings na média.
- Custoso para chaves com prefixos comuns longos. (Caso frequente!)

#### 3-way radix quick sort.

- Usa ~ 2N In N comparações de caracteres na média.
- Evita comparar prefixos comuns longos mais de uma vez.

#### MSD radix sort.

- Não usa bem o cache.
- Gasta muita memória com array count [].
- Muito overhead reinicializando count[] e aux[].

#### 3-way radix quick sort.

- Usa bem o cache.
- É in-place.
- Tem um loop interno curto.

Aula 08 – Radix Sort 46/65

## Sumário: desempenho dos algoritmos de ordenação

algorithm	guarantee	random	extra space	stable?
insertion sort	½ N²	1/4 N <sup>2</sup>	1	~
mergesort	$N \lg N$	N lg N	N	~
quicksort	1.39 N lg N *	1.39 N lg N	c lg N	
heapsort	3 N lg N	3 N lg N	1	
LSD sort †	W (3N + R)	W(3N+R)	N + R	~
MSD sort ‡	W (3N + R)	$N \log_R N$	N + DR	~
3-way string quicksort	1.39 W N lg R *	1.39 N lg N	$\log N + W$	
* probabilistic † fixed-length W key	/S			

Aula 08 - Radix Sort 47/65

average-length W keys

## Radix sorts para strings: análise empírica

Algorithm	dict	book	
System qsort	0.409	0.559	
Standard quick sort	0.430	0.499	
Key-counting sort (Only wor	cks with	strings	of len $= 1$ )
LSD	0.967	0.601	
MSD1: standard	1.327	0.309	
MSD2: cut-off ins-sort	0.229	0.202	
3-way string quick sort	0.161	0.159	
3-way quick sort + cut-off	0.162	0.150	

Conclusão: 3-way radix quick sort é o melhor método conhecido para ordenação de strings.

Aula 08 – Radix Sort 48/65

## Parte VI

# Radix Sort para Números

Aula 08 – Radix Sort 49/65

## Radix sort para inteiros

#### De strings para inteiros:

- Até agora vimos radix sorts para strings.
- Os mesmos algoritmos pode ser usados para ordenar inteiros.
- Basta identificar os componentes de um número.

#### Composição:

- Strings são formadas por caracteres.
- Inteiros são formados por bits e bytes.
- $\blacksquare$  R = 2: análise de um número bit a bit.
- $\blacksquare$  R = 256: análise de um número *byte* a *byte*.

Aula 08 – Radix Sort 50/65

## Radix sort para inteiros: implementação em C

```
typedef int Item;
#define kev(A) (A)
#define less(A, B) (key(A) < key(B))</pre>
#define exch(A, B) { Item t = A; A = B; B = t; }
#define compexch(A, B) if (less(B, A)) exch(A, B)
#define BITS PER WORD 32
#define BITS PER BYTE
#define BYTES_PER_WORD
#define R
                       (1 << BITS PER BYTE)
#define byte(A, B) \
    (((A) >> (BITS PER WORD - ((B)+1) * BITS PER BYTE)) & (R-1))
#define bit(A, B) \
    ((A) >> (BITS PER WORD - ((B)+1)) & 1U)
```

Alerta: contagem de *bits* e *bytes* é da esquerda para direita! *Bit* (*byte*) 0 é o MSD.

Aula 08 – Radix Sort 51/65

#### Quick sort binário

- Tomando R = 2, podemos implementar uma versão binária do quick sort.
- Pivô é o *d*-ésimo *bit*. Sequência por MSD.

Α	00001	Α	00001	Α	0 0 0 0 1	Α	00001	Α	0000	Α	00001
S	10011	Ε	00101	Ε	00101	Α	00001	Α	0000	Α	00001
0	01111	0	01111	Α	0 0 0 0 1	Ε	0 0 1 0 1	Ε	00101	Ε	00101
R	10010	L	01100	Ε	00101	Е	00101	Ε	0 0 1 0	Ε	00101
T	10100	M	01101	G	00111	G	00111	G	0 0 1 1 1	G	00111
1	01001	1	01001	- 1	0 1 0 0 1	- 1	01001	- 1	01001	- 1	01001
Ν	01110	Ν	01110	Ν	0 1 1 1 0	Ν	0 1 1 1 0	L	0 1 1 0 0	L	01100
G	00111	G	00111	М	0 1 1 0 1	М	0 1 1 0 1	M	0 1 1 0 1	М	01101
Ε	00101	Ε	00101	L	0 1 1 0 0	L	0 1 1 0 0	Ν	01110	Ν	0 1 1 1 0
Х	11000	Α	00001	0	0 1 1 1 1	0	0 1 1 1 1	0	0111	0	01111
Α	00001	Х	1 1 0 0 0	S	10011	S	10011	Р	10000	Р	10000
М	01101	Т	10100	Т	10100	R	10010	R	10010	R	10010
P	10000	Ρ	10000	Р	10000	Р	10000	S	10011	S	10011
L	01100	R	10010	R	10010	Т	10100	T	10100	T	10100
Ε	00101	S	10011	Х	1 1 0 0 0	Х	1 1 0 0 0	Χ	1 1 0 0 0	Χ	11000

Aula 08 – Radix Sort 52/65

## Quick sort binário: implementação em C

```
void bin quick sort(Item *a, int lo, int hi, int d) {
    if (hi <= lo || d > BITS PER WORD) return;
    int i = lo, j = hi;
    while (i != i) { // Partition.
        while (bit(a[i], d) == 0 && (i < \dot{j})) { i++; }
        while (bit(a[i], d) == 1 && (i > i)) { i--; }
       exch(a[i], a[j]);
    if (bit(a[hi], d) == 0) { j++; } // All bits = 0.
    bin_quick_sort(a, lo, j-1, d+1); // Recursive sort
    bin guick sort(a, i, hi, d+1); // on next bit.
void sort(Item *a, int N) {
   bin quick sort(a, 0, N-1, 0);
```

Aula 08 – Radix Sort 53/65

### MSD radix sort

- Tomando 1 bit no radix quick sort  $\Rightarrow$  MSD com R = 2.
- Fazendo R = 256 podemos analisar os números byte a byte.
- Com isso o array fica particionado em R partes.
- Tradicionalmente, as partes são chamadas de bins ou buckets.



Aula 08 – Radix Sort 54/65

## MSD radix sort: implementação em C

```
void rec MSD(Item *a, Item *aux, int lo, int hi, int d) {
    if (d > BYTES PER WORD) return;
    if (hi <= lo) return:</pre>
    int count[R+1]:
    count sort (a, aux, count, lo, hi, d);
    rec_MSD(a, aux, lo, lo + count[0] - 1, d+1);
    for (int r = 0; r < R-1; r++) { // Sort R arrays recursively
      rec_MSD(a, aux, lo + count[r], lo + count[r+1] - 1, d+1);
void sort(Item *a, int N) {
    Item* aux = malloc(N * sizeof(Item));
    rec_MSD(a, aux, 0, N-1, 0);
    free (aux);
```

Aula 08 – Radix Sort 55/65

## MSD radix sort: desempenho

#### Considerações sobre o MSD radix sort:

- Fazer R = 256 é uma boa ideia porque as arquiteturas atuais favorecem o acesso por bytes (ao invés de bits).
- O algoritmo MSD consegue deixar um array quase ordenado muito rapidamente.
- Mas, como antes, MSD sofre do problema de desempenho para sub-arrays pequenos.

 $\blacksquare \Rightarrow$  Usar insertion sort.

Aula 08 – Radix Sort 56/65

## MSD radix sort: análise empírica

# Tempo de execução dos algoritmos em segundos para entradas de tamanho 10<sup>7</sup> (10M).

RANDOM NUMBERS Best: quick sort	2.031	SORTED Best: merge sort	0.089
Bin quick sort MSD MSD + cut-off	2.911 10.824 0.782	Bin quick sort MSD MSD + cut-off	1.274 10.814 0.725
REVERSE SORTED Best: quick sort	0.711	NEARLY SORTED Best: merge sort	0.217
Bin quick sort MSD MSD + cut-off	1.286 11.006 0.763	Bin quick sort MSD MSD + cut-off	1.289 10.826 0.730

Aula 08 – Radix Sort 57/65

## 3-way radix quick sort para inteiros

```
void quick_sort(Item *a, int lo, int hi, int d) {
    if (hi <= lo + CUTOFF - 1) {
        insert_sort_from(a, lo, hi, d);
        return:
    int lt = lo, gt = hi;  // 3-way partitioning
    Item v = byte(a[lo], d); // (using dth byte).
    int i = lo + 1;
   while (i <= gt) { // Partition.</pre>
        Item t = byte(a[i], d);
        if (t < v) { exch(a[lt], a[i]); lt++; i++; }</pre>
        else if (t > v) { exch(a[i], a[gt]); gt--; }
        else
                     { i++; }
    quick sort(a, lo, lt-1, d); // Sort 3 sub-arrays
    quick_sort(a, lt, qt, d+1);
    quick sort(a, qt+1, hi, d); // recursively.
void sort(Item *a, int N) {
   quick sort(a, 0, N-1, 0);
```

Aula 08 – Radix Sort 58/65

## 3-way radix quick sort: análise empírica

RANDOM NUMBERS Best: quick sort	2.031	SORTED Best: merge sort	0.089
Bin quick sort MSD MSD + cut-off 3-w-qsort + cut		Bin quick sort MSD MSD + cut-off 3-w-qsort + cut	10.814
REVERSE SORTED Best: quick sort	0.711	NEARLY SORTED Best: merge sort	0.217
Bin quick sort MSD MSD + cut-off 3-w-qsort + cut		Bin quick sort MSD MSD + cut-off 3-w-qsort + cut	

Aula 08 – Radix Sort 59/65

## 3-way radix quick sort: discussão

Q: Por que 3-way radix quick sort é tão bom para strings e tão ruim para inteiros?

A: Devido à forma de economia de trabalho do algoritmo.

- Não re-examina símbolos iguais ao pivô.
- Mas re-examina os símbolos diferentes do pivô.
- A partição de símbolos iguais é em média 10x maior para strings do que para inteiros.

#### Por que essa diferença?

- Inteiro pode ser visto como uma *string* de tamanho fixo.
- Em ambos os casos temos R = 256.
- Mas para strings na prática só comparamos 26 letras.
- Isso aumenta a chance de uma string entrar na partição de símbolos iguais ao pivô.

Aula 08 – Radix Sort 60/65

#### Podemos também implementar a versão LSD radix sort:

```
void sort(Item *a, int N) {
   Item* aux = malloc(N * sizeof(Item));
   int count[R+1];

for (int d = BYTES_PER_WORD - 1; d >= 0; d--) {
      count_sort(a, aux, count, 0, N-1, d);
   }

   free(aux);
}
```

Dado que N >> R a complexidade é linear ( $\sim 12N$ ).

Aula 08 – Radix Sort 61/65

## LSD radix sort: análise empírica

RANDOM NUMBERS	0.001	SORTED	0 000
Best: quick sort		Best: merge sort	0.089
Bin quick sort	2.911	Bin quick sort	1.274
MSD	10.824	MSD	10.814
MSD + cut-off	0.782	MSD + cut-off	0.725
3-w-qsort + cut	3.124	3-w-qsort + cut	14.568
LSD	0.554	LSD	0.552
REVERSE SORTED		NEARLY SORTED	
Best: quick sort	0.711	Best: merge sort	0.217
Bin quick sort	1 286	Bin quick sort	1 289
-	11.006	MSD	10.826
MSD + cut-off		MSD + cut-off	
3-w-qsort + cut		3-w-qsort + cut	
LSD	0.558	LSD	0.552

Aula 08 – Radix Sort 62/65

## LSD radix sort: discussão

#### Strings vs. inteiros:

- LSD não é recomendado para *strings* de tamanho variável.
- Inteiros sempre têm o mesmo tamanho (em *bytes*).

#### Por que LSD radix sort é tão eficiente?

- Algoritmo faz BYTES\_PER\_WORD passadas no array.
- Desempenho de count\_sort () é linear em relação a N.
- Forma de acesso aos bytes é "arch-friendly".

#### Mas MSD radix sort não tem complexidade sub-linear?

- Sim, mas só no melhor caso.
- Na prática, os detalhes de implementação influenciam.
- Overhead das chamadas recursivas.
- Pouca localidade de cache.

Aula 08 – Radix Sort 63/69

## Métodos de ordenação: conclusão

#### Vários métodos:

- Todos os métodos de ordenação estudados têm uma aplicação em algum cenário específico.
- Algoritmos como merge sort e quick sort são os mais usados na prática.
- Justificativa para tal é a facilidade de adaptação para diferentes tipos de chave.
- Radix sorts podem ter desempenho sub-linear em situações especiais.

#### Mensagem final:

- O sort do sistema foi projetado e testado para ter um bom desempenho na grande maioria dos casos.
- Nas situações especiais em que o desempenho não for suficiente, há métodos específicos melhores.

Aula 08 – Radix Sort 64/65

## Aula 08 – Radix Sort

#### Prof. Eduardo Zambon

Departamento de Informática (DI) Centro Tecnológico (CT) Universidade Federal do Espírito Santo (UFES)

Estrutura de Dados II (ED2)

Aula 08 – Radix Sort 65/65